Trabajo en clase
Aprendizaje Automático
Raul Paredes, M. Sc.

Taller. Preprocesamiento de base de datos

Una institución de salud desea desarrollar posteriormente un sistema basado en **Machine Learning** capaz de identificar si un paciente presenta características asociadas con una enfermedad cardíaca.

Para ello, el equipo de estudiantes recibe un conjunto de datos que contiene información demográfica, clínica y resultados de diferentes pruebas médicas.

Sin embargo, los datos originales **no se encuentran preparados para ser utilizados directamente por un algoritmo de Machine Learning**.

Como equipo de análisis de datos, deberán realizar el proceso completo de **exploración, limpieza, transformación y preparación de los datos**, hasta obtener un conjunto de datos listo para la etapa de entrenamiento de un modelo de clasificación.

Importante: durante esta actividad **NO se debe entrenar ningún modelo de Machine Learning**.

El objetivo es demostrar que el equipo puede identificar problemas en los datos, seleccionar estrategias apropiadas de tratamiento y justificar técnicamente cada decisión.

Variable	Significado	Tipo	Ejemplo
age	Edad del paciente, en años	Numérica	`63`
sex	Sexo biológico: `1` = hombre, `0` = mujer	Binaria	`1`
cp	Tipo de dolor de pecho (*chest pain*)	Categórica	`1`, `2`, `3`, `4`
trestbps	Presión arterial en reposo, mmHg	Numérica	`145`
chol	Colesterol sérico, mg/dL	Numérica	`233`
fbs	Glucemia en ayunas > 120 mg/dL: `1` = sí, `0` = no	Binaria	`1`
restecg	Resultado del electrocardiograma en reposo	Categórica	`0`, `1`, `2`
thalach	Frecuencia cardíaca máxima alcanzada	Numérica	`150`
exang	Angina inducida por ejercicio: `1` = sí, `0` = no	Binaria	`0`
oldpeak	Depresión del segmento ST inducida por ejercicio respecto al reposo	Numérica	`2.3`
slope	Pendiente del segmento ST durante el ejercicio	Categórica	`1`, `2`, `3`
ca	Número de vasos principales coloreados por fluoroscopia	Discreta	`0`, `1`, `2`, `3`
thal	Resultado de la prueba de talasemia	Categórica	`3`, `6`, `7`
target	Variable objetivo: presencia/ausencia de enfermedad cardíaca	Binaria	`0` / `1`

Objetivo general

Preparar un conjunto de datos clínicos para su posterior utilización en un modelo de Machine Learning, aplicando técnicas de exploración, limpieza, transformación, codificación, división y escalamiento de datos, evitando problemas de fuga de información (data leakage).

Objetivos específicos

Al finalizar la actividad, el estudiante será capaz de:

Trabajo en clase
Aprendizaje Automático
Raul Paredes, M. Sc.

Universidad de Las Américas

1. **Analizar** la estructura y características de un dataset real.
2. **Identificar** diferentes tipos de variables presentes en un conjunto de datos.
3. **Detectar** valores faltantes, duplicados y posibles valores atípicos.
4. **Seleccionar y justificar** estrategias para el tratamiento de datos faltantes.
5. **Diferenciar** variables numéricas, binarias, categóricas y ordinales.
6. **Transformar** variables categóricas mediante técnicas de codificación apropiadas.
7. **Separar** las variables predictoras de la variable objetivo.
8. **Dividir** correctamente los datos en conjuntos de entrenamiento y prueba.
9. **Aplicar** escalamiento de variables evitando data leakage.
10. **Documentar y justificar** las decisiones tomadas durante el preprocesamiento.

Restricciones

- No eliminar columnas únicamente porque presentan problemas.
- No eliminar registros sin justificar la decisión.
- No asumir que una variable es numérica solamente porque contiene números.
- No aplicar transformaciones indiscriminadamente a todas las variables.
- Toda decisión de preprocesamiento debe estar respaldada por evidencia obtenida del análisis de los datos.

Resultado esperado

Al finalizar la actividad, el grupo deberá ser capaz de demostrar que el conjunto de datos pasó de ser un conjunto de datos **contaminado y no confiable** a un conjunto de datos **consistente y preparado para la siguiente etapa de Machine Learning**, justificando técnicamente cada transformación realizada.

Entregables

1. Notebook / GoogleColab con el código ejecutado
2. Tabla de decisiones de pre - procesamiento

Problema	Decisión	Justificación
Valores faltantes		
Duplicados		
Outliers		
Variables eliminadas		
Variables categóricas		
Encoding		
Normalización - Scaling		

¿Por qué un buen modelo de Machine Learning depende de un adecuado proceso de preprocesamiento de datos?

Trabajo en clase
Aprendizaje Automático
Raul Paredes, M. Sc.

Universidad de Las Américas

Rúbrica de evaluación

Criterio	Excelente — 4	Bueno — 3	Básico — 2	Insuficiente — 1	Ponderación
1. Exploración y comprensión del dataset	Analiza completa y correctamente estructura, dimensiones, tipos de variables, estadísticos y variable objetivo. Interpreta los resultados.	Realiza correctamente la exploración, aunque la interpretación es parcial.	Realiza una exploración básica con poca interpretación.	Exploración incompleta, incorrecta o sin interpretación.	**1.0**
2. Identificación y tratamiento de problemas de calidad	Identifica correctamente faltantes, duplicados, inconsistencias y posibles anomalías; selecciona y justifica estrategias apropiadas para cada caso.	Identifica la mayoría de problemas y aplica estrategias adecuadas, aunque con justificación parcial.	Identifica algunos problemas, pero las estrategias presentan poca justificación o errores menores.	No identifica problemas importantes o aplica tratamientos incorrectos sin justificación.	**1.5**
3. Análisis y tratamiento de valores atípicos	Detecta y analiza los outliers mediante visualizaciones y criterios estadísticos; decide correctamente si conservar/eliminar y justifica técnicamente.	Detecta los principales outliers y toma decisiones razonables, con justificación parcial.	Detecta algunos outliers, pero el análisis es superficial o las decisiones están poco justificadas.	No analiza outliers o los elimina automáticamente sin justificación.	**1.0**
4. Selección y transformación de variables	Clasifica correctamente variables numéricas, binarias, nominales y ordinales; selecciona variables relevantes y aplica técnicas de transformación apropiadas.	Clasifica y transforma correctamente la mayoría de variables, con pequeños errores de criterio.	Presenta algunas confusiones entre tipos de variables o utiliza transformaciones poco justificadas.	Clasifica incorrectamente las variables o aplica transformaciones inadecuadas.	**1.5**
5. Separación de variables predictoras y objetivo	Define correctamente `X` e `y` y explica claramente por qué la variable objetivo no debe formar parte de `X`.	Realiza correctamente la separación, pero la explicación es limitada.	Realiza la separación con algún error menor o explicación insuficiente.	Confunde las variables predictoras con la variable objetivo.	**0.5**
6. División Train/Test	Realiza correctamente la división y explica `test_size`, `random_state` y especialmente el uso de `stratify`.	Realiza correctamente la división y comprende sus principales parámetros.	Realiza la división, pero presenta dificultades para explicar su propósito o parámetros.	No realiza correctamente la división o utiliza información de test durante el entrenamiento/preprocesamiento.	**1.0**
7. Escalamiento y prevención de Data Leakage	Aplica correctamente `fit`únicamente sobre entrenamiento y `transform` sobre test; identifica y explica claramente el problema de Data Leakage.	Aplica correctamente el escalamiento y reconoce el riesgo de Data Leakage, aunque la explicación es parcial.	Aplica el escalamiento con errores menores o demuestra comprensión limitada del Data Leakage.	Escala antes de separar Train/Test o presenta Data Leakage evidente y no lo identifica.	**1.5**
8. Justificación técnica de las decisiones	Justifica de manera clara, coherente y fundamentada las principales decisiones de preprocesamiento. Relaciona las decisiones con el comportamiento esperado del modelo.	Justifica adecuadamente la mayoría de decisiones.	Presenta justificaciones generales, poco profundas o basadas principalmente en procedimientos.	No justifica las decisiones o las justificaciones son incorrectas.	**1.0**
9. Organización del notebook y trabajo colaborativo	Notebook ordenado, reproducible, código claro, resultados correctamente presentados y evidencia de distribución efectiva del trabajo.	Notebook organizado y funcional, con pequeños problemas de presentación u organización.	Notebook funcional pero desordenado o con poca documentación.	Notebook incompleto, desorganizado o difícil de reproducir.	**1.0**
TOTAL					**10.0**